遇事不决可问智药 29029

Smart Medicine Box

主数据报表

模块	模型名	type	shape / 配置	1 Core/ms	2 Core/ms	4 Core/ms	核心技术
人脸识别	yolov5n-face_320_cut.q.onnx	int8	320x320	84.0	83.3	84.0	SpaceMIT + CPU EP + 128维人脸特征 + 人脸库name.npy + 余弦相似度匹配 + member ID排序 + 步长卷积，特征融合卷积
PILL	yolov8n	int8	640x640	271.260	187.567	143.989	SpaceMIT + CPU EP+ OV5647实拍训练YOLOv8n模型 + Conv2d,1×1/3×3卷积，下采样卷积，特征融合卷积
OCR药盒 det	ppocr_v5_mobile_det_onnx_infer	int8	1x3x352x640	202.634	192.765	179.019	SpaceMIT官方加速路径
OCR药盒 rec	ppocr_v5_mobile_rec_onnx_infer	int8	1x3x48x320	113.897	96.193	91.249	SpaceMIT + CPU rec 回退 Conv.7;Conv.11;Conv.21;Conv.29 到 CPU
OCR药单 det	ppocr_v5_mobile_det_int8_audited_portrait_1x3x960x544.onnx	int8	1x3x960x544	330.053	191.847	173.635	SpaceMIT官方加速路径
OCR药单 rec	ppocrv5_mobile_rec_prescription_int8_1x3x48x320.onnx	int8	1x3x48x320	118.262	112.347	114.448	SpaceMIT + CPU rec 回退 Conv.7;Conv.11;Conv.21;Conv.29 到 CPU

OCR共性：
1.大量数据微调FP32 + 适量数据校准 INT8量化
2.QAT量化感知训练
3.通过 GStreamer / spacemitsrc 管线采集 OV5647 图像
4.vision_lock 防止多个视觉任务同时抢摄像头

ASR

模型名	type	正式版线程	RTF	核心技术
SenseVoice official optimized	dyn_int8	AIEngine	0.393	sense voice量化ONNX+VAD静音裁剪+增益归一化+spaceMIT llama server

LLM

模型名	量化类型	PP128	TG128	核心技术
qwen3-0.6B (TCM禁用)	Q4_0	63.29	9.92	1.SpaceMIT llama.cpp加速引擎驱动 2.llama-server 把本地 LLM 封装成 HTTP 服务 3.通过规则优先、Prompt 限制和本地事实约束，避免 LLM 自由生成医疗决策
qwen3-0.6B (TCM启用)	Q4_0	43.37	10.61	1.SpaceMIT llama.cpp加速引擎驱动 2.llama-server 把本地 LLM 封装成 HTTP 服务3.通过规则优先、Prompt 限制和本地事实约束，避免 LLM 自由生成医疗决策

模块亮点

人脸识别
1.稳定两帧检测到人脸再开始录入
2.YOLO Face det + ArcFace 双线程
3.人脸库 name.npy 对应前端输入的真实姓名

ASR
1.启动时 amixer 初始化麦克风，避免静音拖慢，保证特征提取稳定
2.job ID + 状态机管理，保证流程稳定

QA / LLM
1.FAQ 库 + 本地LLM 优化生成答案
2.药名拼音置信度回归+问题语义归类 + 余弦相似度辅助归类
3.FAQ 库中事实对应问题，按语义回答

PILL
1.OV5647 常驻，确保拿到稳定新帧，避免 AE / ISP 抖动问题
2.只拿最新一帧 + 单次推理，避免内存积压，省资源
3.识别中按钮禁用，后端任务 busy保护，避免用户连续点击造成并发识别

OCR药盒
1. det 画框 + rec 文字识别 + 药名库的结构化包装。
2.vision_lock 防止多个视觉任务同时抢摄像头
3. rec 仅识别前三大框文字 + 药名库匹配，节省算力资源

OCR药单
1. vision_lock 防止多个视觉任务同时抢摄像头
2. 药品数据库及常见用语置信度校准
3. 特殊用语翻译（如 bid = 一日两次）
4. 药品信息自动填充，支持手工纠错

生命周期与资源配置

内容	人脸识别	ASR	QA / LLM	PILL	OCR药盒	OCR药单
开机状态	并行preload +ov5647常驻					
CPU 占用	绑定核 3	AIEngine	0~3 核	绑定核 2	绑定核 1	绑定核 1
EP 线程	1	AIEngine	4	1	1	1
TCM 策略	使用	AIEngine	禁用	使用	使用	使用
推理方式	串行					
单任务结束	释放推理权/会话/相机					
关机	统一release					

整体亮点

01 1. 全链路端侧化、本地部署(保护用药、人脸和语音隐私)、开机所有独立模块冷启动。

02 2.多个重任务通过 preload、常驻、串行调用、推理权释放、统一 release 等生命周期管理，避免模型和相机互相抢资源。

03 3. OV5647 负责药盒、药单OCR 和药片识别，IMX219 负责人脸识别；不同任务有相机锁和识别区分工，降低冲突。

04 4. 多模型（FACE、PILL、OCR、ASR）前期训练校准并且量化，兼具性能和板端算力，符合边缘设备的部署思路。

05 5. 模块分工明确：人脸负责身份，ASR 负责文字输入，OCR 和 YOLO 负责视觉识别，LLM 负责语义决策。

06 6. 从成员建档、药单/药盒识别、放药入柜、到点提醒、人脸核验、取药监督、数量核验到记录报告，形成完整产品流程。

遇到的问题 & 解决方案

问题：OCR rec 中 conv 有 4 个节点不稳定SpaceMIT 硬件加速编译报错。
方案：用 name filter 强制这几层卷积不走硬件加速，回退到 CPU。

问题：任务转换时 failed to fetch 报错。
方案：让 OV5647 常驻并添加相机锁进行管理。

问题：Linux 音频有时因USB插口改变而无法正常识别
方案：以ALSA 声卡麦克风硬件设备号为唯一判定。

问题：任务卡死堵塞时推理权无法正常交接
方案：设置timeout，安全释放推理权给下一个任务。